

AI大模型应用：NLP与大模型


2025/2026年

内部资料，请勿外传

模态与多模态

模态 (Modality): 指信息呈现和存储的不同类型和格式。它是理解事物发生方式和经验过程的关键元素。

多模态: 处理和整合多种模态或数据类型的信息。这些模态可以包括文本、图像、音频、视频和其他形式的感官输入。




模态与多模态

模态 (Modality): 指信息呈现和存储的不同类型和格式。它是理解事物发生方式和经验过程的关键元素。



常见模态类型

- 自然语言：口语、书写等
- 视觉：图片、视频等
- 听觉：声音、音乐等
- 触觉
- 嗅觉、味觉
- 生理信号：心电图、皮肤电导信号
- 其他模态：红外线、深度成像、fMRI



多模态大模型

多模态大模型是一种能够处理和理解多种类型数据（如文本、图像、音频和视频）的人工智能模型。



多模型大模型能做什么？

文生图（内容生成）：文本描述 -> 模型 -> 图像；

图生图（风格迁移、内容迁移）：图像 + 文本描述 -> 模型 -> 图像；

图生视频（视频生成）：图像 + 文本描述 -> 模型 -> 视频；

语音/图像生视频（数字人合成）：语音/图像 + 参考图像 -> 视频；

图文问答：图 + 提问 -> 模型 -> 文本回答；

图文标注：图 + 任务 -> 模型 -> 标注结果；



多模态编码：视频/语音/文本/图像 -> 模型 -> 嵌入向量；

多模型微调

■ LoRA (Low-Rank Adaptation) 大模型加速微调 and 训练算法

$$\tilde{W}_0 = W_0 + \Delta W$$

$$W_0 + \Delta W = W_0 + BA, B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}$$



LoRA 缩放系数 α/r : 实际计算时, $\Delta W \times$ 需要乘以缩放系数 α/r 。在最早的 LoRA 中, 该系数被设置为 2, 即 α 是 r 的两倍, 而在后续研究一般将其设置为 1。缩放系数越大, 表明微调部分的权重越大。

LoRA 层: 微调的过程中, 可以仅对部分 Transformer 层中的权重矩阵采用 LoRA 算法。比如, 可以指定仅在 Q/K/V 中部分层。研究表明, 对整个神经网络的所有层采用 LoRA 算法的效果是最好的。

LoRA dropout: 表示 LoRA 层 dropout 的概率, 目的是为了 avoid 过拟合。对于 13B 等小模型, 一般设置成 10%, 而对于 65B 等更大规模模型, 一般设置成 5%。


■ 前向传播

$$h = W_0 x + \Delta W x = W_0 x + BAx \quad W = W_0 + BA$$

多模型微调

文本指令微调

多模态指令微调



以图文数据为例

□ 图像-文本指令遵循数据 (Instruction-Following Data) 数据组成如下:

- 1) 图像文件
- 2) 指令文本 (即描述执行的任务)
- 3) 指令的执行结果


json

Copy code

```
{
  "instruction": "请分析上面这句话的情感, 50汉字内",
  "input": "鄢懋卿, 冒青烟! 朕的钱! 他们拿两百万, 朕分一百万, 还要朕感谢他们嘛!",
  "output": "这句话表达了愤怒和不满。说话者对某些人获取金钱的不满, 认为自己已做出让步, 却仍被要求..."
}
```

上下文 类型1: 描述

一群人站在一辆黑色车辆外, 周围有各种行李。行李围绕着一个地下停车场的车辆。人们试图将他们所有的行李装进一辆 SUV。这辆运动型多用途车停在公共车库里, 正在为旅行装载。一些人和行李靠近一辆正在运送行李的面包车。



图像数据

上下文 类型2: 边界框

人物:[0.681,0.242,0.774,0.694], 背包:[0.384,0.696,0.485,0.914], 行李箱:.....

类型1: 对话

问题: 图片中是什么类型的车辆?

指令数据

回答: 图片中是一辆黑色的运动型多用途车 (SUV)。

问题: 车辆停在哪里?

回答: 车辆停在一个地下停车场, 可能是在一个公共车库里。

执行结果

类型 2: 详细描述

问题: 请你详细描述该图片中的场景。

回答: 图片显示了一个地下停车场, 其中停着一辆黑色的运动型多用途车 (SUV)。场景中有三个人, 一个人站在车辆左侧较近的位置, 另一个人在中间, 第三个人在右侧。他们正在一起将行李装进 SUV 里, 为旅行做准备....

类型 3: 复杂推理

问题: 这些人面临什么挑战?

回答: 在这张图片中, 一群人站在一个停车场里的一辆黑色 SUV 外, 周围散落着各种行李, 包括行李箱和背包。他们面临的挑战是将所有行李装进这辆黑色 SUV 中。有多个行李箱和背包需要装载.....


多模型微调

```
{
  "messages": [
    {
      "content": "<image>Who are they?",
      "role": "user"
    },
    {
      "content": "They're Kane and Gretzka from Bayern Munich.",
      "role": "assistant"
    },
    {
      "content": "What are they doing?",
      "role": "user"
    },
    {
      "content": "They are celebrating on the soccer field.",
      "role": "assistant"
    }
  ],
  "images": [
    "mllm_demo_data/1.jpg"
  ]
},
```

```
{
  "messages": [
    {
      "content": "<video>Why is this video funny?",
      "role": "user"
    },
    {
      "content": "Because a baby is reading, and he is so cute!",
      "role": "assistant"
    }
  ],
  "videos": [
    "mllm_demo_data/1.mp4"
  ]
},
```

https://github.com/hiyouda/LLaMA-Factory/blob/main/data/mllm_video_demo.json

多模型微调




□ 模态编码器(图①)

- 多种模态(图片、音频、视频)的数据进行特征提取和编码，将**原始输入**转换为**高维特征表示**

○ 说明：

- 1) 特征提取：**不同模态数据使用不同网络架构**进行特征提取。
- 2) 嵌入层：每种模态的特征经过处理后，都会被**映射到一个统一的嵌入空间**中，这样不同模态的特征可以在同一空间内进行比较和融合。


计算机视觉



```
[[105 112 108 111 104 99 106 99 96 103 112 119 104 97 93 87]
 [ 91 98 102 106 104 79 98 103 99 105 123 136 110 105 94 85]
 [ 76 85 90 105 128 105 87 96 95 99 115 112 106 103 99 85]
 [ 99 81 81 93 120 131 127 100 95 98 102 99 96 93 101 94]
 [106 91 61 64 69 91 88 85 101 107 109 98 75 84 96 95]
 [114 108 85 55 55 69 64 54 64 87 112 129 98 74 84 91]
 [133 137 147 103 65 81 80 65 52 54 74 84 102 93 85 82]
 [128 137 144 140 109 95 86 70 62 65 63 63 60 73 86 101]
 [125 133 148 137 119 121 117 94 65 79 80 65 54 64 72 98]
 [127 125 131 147 133 127 126 131 111 96 89 75 61 64 72 84]
 [115 114 109 123 150 148 131 118 113 109 100 92 74 65 72 78]
 [ 89 93 90 97 108 147 131 118 113 114 113 109 106 95 77 80]
 [ 63 77 86 81 77 79 102 123 117 115 117 125 125 130 115 87]
 [ 62 65 82 89 78 71 80 101 124 126 119 101 107 114 131 119]
 [ 63 65 75 88 89 71 62 81 120 138 135 105 81 98 110 118]
 [ 87 65 71 87 106 95 69 45 76 130 126 107 92 94 105 112]
 [118 97 82 86 117 123 116 66 41 51 95 93 89 95 102 107]
 [164 146 112 80 82 120 124 104 76 48 45 66 88 101 102 109]
 [157 170 157 120 93 86 114 132 112 97 69 55 70 82 99 94]
 [130 128 134 161 139 100 109 118 121 134 114 87 65 53 69 86]
 [128 112 96 117 150 144 120 115 104 107 102 93 87 81 72 79]
 [123 107 96 86 83 112 153 149 122 109 104 75 80 107 112 99]
 [122 121 102 80 82 86 94 117 145 148 153 102 58 78 92 107]
 [122 164 148 103 71 56 78 83 93 103 119 139 102 61 69 84]]
```

数字图像 (Digital Image) 可看作 $f(x, y)$ 的离散采样, 在计算机中由数组或矩阵表示, 其光照位置和强度都是离散的。其中, 矩阵的单个元素被称作像素 (Pixel), 数字图像可以用数字计算机或数字电路存储和处理。

计算机视觉







计算机视觉


	Classification分类	Segmentation分割	Detection检测
简介	 → 'Cat'		
输入	Image [C, W, H] 	Image [C, W, H] 	Image [C, W, H] 
输出	Vector: [, N class] [0.2, 0.4, 0.3, 0.1]	Image [C, W, H] 	Vector: [X1, Y1, X2, Y2, Score, Class1, Class2, ..., ClassN] [100, 120, 755, 400, 0.7, 0.2, 0.1, 0.1]
标签	Vector: [N class] [happy]	Image [C, W, H] 	Vector: [X1, Y1, X2, Y2, Class] [100, 110, 760, 430, car]
损失函数	Cross-Entropy Loss	Binary Cross-Entropy Loss, Dice Loss、 Focal Loss	MSE Loss+Cross-Entropy Loss

卷积神经网络


卷积经常用在信号处理中，用于计算信号的延迟累积。不同的滤波器来提取信号序列中的不同特征。在图像处理中，图像是以二维矩阵的形式输入到神经网络中，因此我们需要二维卷积。




卷积神经网络




步长1，零填充0




步长2，零填充0




步长1，零填充1



步长2，零填充1



(a) 全连接层



(b) 卷积层

卷积神经网络

Input (zero-padding) (7x7x3)

$x[:, :, 0]$

0	0	0	0	0	0	0
0	1	0	0	0	0	0
0	2	1	1	2	1	0

Filter W0 (3x3x3)

$w0[:, :, 0]$

1	1	1
0	-1	0
0	-1	1

$w0[:, :, 1]$

0	-1	-1
1	-1	-1
1	1	-1

$w0[:, :, 2]$

0	1	0
-1	-1	-1
-1	-1	0

Bias b0 (1x1x1)

$b0[:, :, 0]$

1

$x[:, :, 1]$

0	0	0	0	0	0	0
0	1	0	0	1	2	0
0	0	1	0	0	2	0

0	2	1	2	2	1	0
0	1	0	2	1	1	0
0	2	1	1	0	2	0

$x[:, :, 2]$

0	0	0	0	0	0	0
0	0	2	2	2	1	0
0	0	1	1	1	0	0

0	0	0	1	0	1	0
0	2	0	1	1	0	0
0	2	2	2	0	2	0

0	0	0	0	0	0	0
---	---	---	---	---	---	---

Filter W1 (3x3x3)

$w1[:, :, 0]$

0	1	1
-1	-1	-1
0	0	1

$w1[:, :, 1]$

-1	1	0
1	0	0
1	-1	-1

$w1[:, :, 2]$

0	0	-1
-1	-1	0
-1	-1	0

Bias b1 (1x1x1)

$b1[:, :, 0]$


0

Output (3x3x2)

$o[:, :, 0]$


-5		

$o[:, :, 1]$



卷积神经网络

卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。




卷积神经网络

卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。


趋向于小卷积、大深度

趋向于全卷积



一个卷积块为连续 M 个卷积层和 b 个汇聚层（ M 通常设置为2 ~ 5， b 为0或1）。一个卷积网络中可以堆叠 N 个连续的卷积块，然后在接着 K 个全连接层（ N 的取值区间比较大，比如1 ~ 100或者更大； K 一般为0 ~ 2）。

卷积神经网络



典型的图像分类模型

在卷积网络中，如何设置卷积层的卷积核大小是一个十分关键的问题。

在Inception网络中，一个卷积层包含多个不同大小的卷积操作，称为Inception模块。

Inception模块同时使用 1×1 、 3×3 、 5×5 等不同大小的卷积核，并将得到的特征映射在深度上拼接（堆叠）起来作为输出特征映射。




Figure 5. Inception modules where each 5×5 convolution is replaced by two 3×3 convolution, as suggested by principle 3 of Section 2.

<http://blog.csdn.net/xbinworld>





Figure 6. Inception modules after the factorization of the $n \times n$ convolutions. In our proposed architecture, we chose $n = 7$ for the 17×17 grid. (The filter sizes are picked using principle 3)

<http://blog.csdn.net/xbinworld>

R-CNN模型


R-CNN将深度学习用于目标检测，在PASCAL VOC 2007数据集上的检测精度从29.2%提升到66.0%，提高了目标检测的准确率。

- ✓ 步骤1：使用选择性搜索 (Selective Search)从待检测图像中提取2000个左右的候选框，将所有的候选
- ✓ 框缩放成固定大小的尺寸(227×227 像素)。
- ✓ 步骤2：利用深度卷积神经网络对候选区进行特征提取，得到固定长度的特征向量；
- ✓ 步骤3：最后把特征向量送入支持向量机分类器进行分类得到类别信息，送入全连接网络进行回归得到
- ✓ 对应位置坐标信息。



YOLO模型

YOLO (you only look once) , 只需要浏览一次就可以识别出图中的物体的类别和位置。



YOLO模型

YOLOv1将图像分成 $S \times S$ 个网格(grid cell), 如果某个object的中心 落在这个网格中, 则这个网格就负责预测这个object。

每个网格需要预测B个BBox的位置信息和confidence (置信度) 信息, 一个BBox对应着四个位置信息和 一个confidence信息。

一张图像输入给网络, 网络最后输出一个 $7 \times 7 \times 30$ 尺寸的特征图 (Feature Map)

7*7 为原图经过降维之后的输出结果

30为通道数 ($2 \times 5 + 20$)

每个bbox包含五个输出参数: 置信度C 和矩形框(c_x, x_y, w, h), 共10个参数
20个类别 (PASCAL VOC类别个数)

YOLOv1有三部分输出, 分别是objectness、class以及bbox:

- ✓ objectness 就是上面所说的框的置信度, 用于表征该网格是否有物体;
- ✓ class 类别预测;
- ✓ bbox 边界框(bounding box);

ViT模型

1. 图像嵌入模块




图 7.1: ViT 架构

假设输入图像 $X \in \mathbb{R}^{H \times W \times C}$ ，其中 $H \times W$ 表示图像分辨率， C 为图像通道数

ViT 将其切分为图像块 (Patch)，并将每个图像块展成一维向量，形成序列数据 $X_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$

其中 (P, P) 为图像块大小， $N = H \times W / P^2$ 为图像块数目，即切分后的序列长度。

ViT模型

1. 图像嵌入模块




图 7.1: ViT 架构

$X_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$ 还会经过线性映射层，将其转换为 $N \times D$ 的矩阵，即图块嵌入（Patch Embedding）。

ViT在图块嵌入的开头添加了一个 D 维嵌入 x_{class} ，用于总结图像整体信息并获得最终的图像表示。

ViT模型

2. 编码




图 7.1: ViT 架构

ViT堆叠若干个Transformer编码器以实现图像表示的提取，这里假设有 L 个编码器模块。每个编码器模块由多头自注意力及多层感知机构成，同时包括残差连接及层归一化操作，与自然语言处理领域中的Transformer一致。

ViT模型

3. 分类




图 7.1: ViT 架构

ViT以输入序列开头的 x_{class} 所对应的编码器输出 z_L^0 作为图像表示，其包含了图像的全局信息。

为实现图像分类，ViT将图像表示送入分类头中。


在预训练阶段，ViT使用具有一层隐藏层的多层感知机作为分类头，微调使用单层线性映射作为分类

CLIP模型

CLIP (Contrastive Language-Image Pre-Training) 模型是一种**基于对比学习**的多模态模型。

对比学习是弱监督学习的有效方法。

- 对比学习是一种学习方法，侧重通过对比正反两方面的实例来提取有意义的表征。
- 它利用的假设是，在学习到的嵌入空间中，相似的实例应靠得更近，而不相似的实例应离得更远。
- 通过将学习作为一项辨别任务，对比学习允许模型捕捉数据中的相关特征和相似性。




CLIP模型

CLIP (Contrastive Language-Image Pre-Training) 模型是一种**基于对比学习**的多模态模型。

对比学习是弱监督学习的有效方法。

- 对比学习是一种学习方法，侧重通过对比正反两方面的实例来提取有意义的表征。
- 它利用的假设是，在学习到的嵌入空间中，相似的实例应靠得更近，而不相似的实例应离得更远。
- 通过将学习作为一项辨别任务，对比学习允许模型捕捉数据中的相关特征和相似性。



CLIP模型

CLIP (Contrastive Language-Image Pre-Training) 模型是一种**基于对比学习**的多模态模型。

文本编码器

- 用于提取文本特征;
- 采用NLP中常用的面向文本的Transformer 模型

图像编码器


- 用于提取图像特征;
- 采用常用的CNN模型或者ViT模型

CLIP核心思想

使用海量的**弱监督**文本通过**对比学习**，将图像和文本映射到一个共享的向量空间，理解图像与文本之间的语义关系

CLIP模型

CLIP (Contrastive Language-Image Pre-Training) 模型是一种**基于对比学习**的多模态模型。



CLIP模型


- 数据特征提取：假设一个训练批次包含 N 个文本-图像对

- 文本编码器对 N 个文本进行文本编码，将每个文本描述转换为一个固定长度的特征向量（维度为 d ），则该训练批次文本数据输出的特征矩阵为

$$\mathbf{T} = [\mathbf{T}_1, \mathbf{T}_2, \dots, \mathbf{T}_N]$$

其中，

$$\mathbf{T} \in \mathbb{R}^{N \times d}, \mathbf{T}_j \in \mathbb{R}^d, j = 1, 2, \dots, N$$




- 图像编码器对这 N 个图像进行图像编码，将每张图像转换为一个固定长度的特征向量（维度为 d ，与文本特征向量长度一致），则该训练批次图像数据输出的特征矩阵为

$$\mathbf{I} = [\mathbf{I}_1, \mathbf{I}_2, \dots, \mathbf{I}_N]$$

其中，

$$\mathbf{I} \in \mathbb{R}^{N \times d}, \mathbf{I}_j \in \mathbb{R}^d, i = 1, 2, \dots, N$$




CLIP模型

- 相似度计算：计算每对特征之间的相似度

- 每个图像特征向量与每个文本特征向量进行组合，形成 N^2 个特征对
- 在 N^2 个特征对中，将 N 个完全匹配的文本-图像对记为正样本，其余 $N^2 - N$ 个不匹配的文本-图像对记为负样本



正负样本可作为正负标签，用来训练文本编码器和图像编码器




- 使用余弦相似度 (Cosine Similarity) 来计算每对特征之间的相似度，即 I_i 和 T_j 的余弦相似度

CLIP模型

- 利用CLIP模型做零样本图像分类步骤:

- **分类标签转换**: 根据任务的分类标签构建每个类别的描述文本: A photo of {label}/某个物品的图片


例如: 对于事物分类任务, 标签集可以是 [“树”, “草”, $\dots$, “农夫”]:
为每个标签生成文本描述, 如 “树的图片” 和 “草的图片” 等。




- **特征抽取**: 将这些文本送入文本编码器, 如果类别数目为N, 将得到N个类别特征

CLIP模型

- 首先，将需要分类的图像（单张图像）输入图像编码器中，从而得到这张图像编码后的**特征向量 I_1**
- 将 I_1 与得到的 N 个文本特征分别计算余弦相似度，找出 N 个相似度中最大的那一个（图中 T_3 ）
- 选择**相似度最高的文本对应的类别**作为图像分类的预测结果



多模态大模型



<https://arxiv.org/pdf/2306.13549>

多模态大模型

Below is an instruction that describes a task. Write a response that appropriately completes the request

Instruction: `<instruction>`

Input: `{<image>, <text>}`

Response: `<output>`

`<BOS>` Below are some examples and an instruction that describes a task. Write a response that appropriately completes the request

Instruction: `{instruction}`

Image: `<image>`

Response: `{response}`

Image: `<image>`

Response: `{response}`

Image: `<image>`


Response: `<EOS>`

多模态大模型

Question / Prompt: You are a professional self-driving agent and good at observing LiDAR point clouds and making driving decisions. I will show you some BEV point cloud images. Please use simple, clear, structured language to describe the road condition, surroundings, abnormal situation and driving strategy.

GPT-4V Answer: The BEV LiDAR image suggests a multi-lane road, but the exact number of lanes and presence of traffic are unclear. There are no visible obstacles, pedestrians, or significant environmental features in the immediate vicinity of the vehicle. The image lacks detail on road surface quality and surrounding signage or traffic lights. In this scenario, maintaining a steady speed while staying within the detected lanes, and being alert for unseen hazards is advisable.

Input LiDAR Point Cloud: [163]



Question / Prompt: As the AI system on an autonomous vehicle, your role is to analyze the driving context and make informed decisions. You will receive an image from the forward-facing camera of the ego vehicle. Please use concise and organized language to describe the current environment, any anomalies, and plan the next steps.

GPT-4V Answer: Driving in an urban setting, the forward-facing camera captures a clear day with multi-story buildings lining both sides of a road, with some patches appearing wet or muddy. The road, populated with cars, motorcycles, and a three-wheeled vehicle. An anomaly to note is the three-wheeled vehicle on the left, which is carrying a heavy load that might affect its stability. Given the situation, the next steps involve maintaining a safe distance from this vehicle, monitoring motorcycles for sudden movements, scanning for traffic signals or signages, and adjusting speed to match the traffic flow.

Input Driving Front View:



Vary (202401)

Vary-toy是由旷视科技、中国科学院大学以及华中科技大学的研究人员合作开发的一款紧凑型视觉语言模型（LVLM）。


- ✓ **文档OCR**: Vary-toy能够识别文档图像中的文字;
- ✓ **图像描述**: 模型可以生成图像的描述文本, 对理解和生成图像描述任务至关重要。
- ✓ **视觉问答 (VQA)**: Vary-toy可以回答关于图像内容的问题;
- ✓ **对象检测**: 模型具有自然对象感知能力, 能在图像中准确识别和定位物体。
- ✓ **图像到文本转换**: Vary-toy能将图像内容转换为结构化文本, 如PDF图像转Markdown;
- ✓ **多模态对话**: 模型支持基于图像内容的对话理解和生成。

Vary (202401)

Task	Dataset	Sample	A prompt example
Cap.	Laion-COCO [39] BLIP558k [26]	4M 558K	Describe the content of this image in a sentence. Describe the image with one saying.
PDF	Pure OCR Markdown	1M 500K	Provide the OCR results of this image. Convert the image to markdown format.
Det.	COCO [24] RefCOCO	50K train set	Detect all objects in this image. Detect an object: the left woman.
NLP	ShareGPT Baize [50] Alpaca [42]	125K 112K 52K	<i>Original conversation</i> <i>Original conversation</i> <i>Original conversation</i>
VQA	DocVQA [30] ChartVQA [29]	train set train set	<i>Qestion</i> .Answer using a single word or phrase. <i>Qestion</i> .Answer using a single-word or phrase.


<https://varytoy.github.io/>

Vary (202401)



BGE-VL (202412)

通过构建异构 KNN 三元组来生成大规模的多模态指令数据集。该方法利用三种不同的相似性模型（CLIP 视觉编码器、DINO 视觉编码器和 CLIP 文本编码器）来采样相关的图像对，并通过多模态语言模型（MLLM）和大型语言模型（LLM）生成描述图像对关系的指令。



BGE-VL (202412)

$\langle \text{instruct} \rangle \{ \text{task_inst} \} \langle \text{query} \rangle \{ q_t \} \{ q_i \} [\text{EOS}]$
(3)

where $\{ \text{task_inst} \}$ represents the task-specific instruction, $\{ q_t \}$ denotes the input query text, and $\{ q_i \}$ is the input query image. The normalized last hidden state of the [EOS] token in the MLLM is used as the embedding of any given input sequence.

$$\mathcal{L} = -\frac{1}{|\mathcal{Q}|} \sum_{q_i \in \mathcal{Q}} \log \frac{\exp(\mathbf{e}_{q_i} \cdot \mathbf{e}_{c_i^+} / \tau)}{\sum_{c_j \in \mathcal{C}} \exp(\mathbf{e}_{q_i} \cdot \mathbf{e}_{c_j} / \tau)}$$


Models	Per Meta-Task Score				Overall
	Classification	VQA	Retrieval	Grounding	
number of datasets	10	10	12	4	36
BLIP2 (Li et al., 2023)	27.0	4.2	33.9	47.0	25.2
SigLIP (Zhai et al., 2023)	40.3	8.4	31.6	59.5	34.8
CLIP (Radford et al., 2021)	42.8	9.1	53.0	51.8	37.8
OpenCLIP (Cherti et al., 2023)	47.8	10.9	52.3	53.3	39.7
UniIR (Wei et al., 2024)	42.1	<u>15.0</u>	60.1[†]	62.2	<u>42.8</u>
MagicLens (Zhang et al., 2024)	38.8	8.3	35.4	26.0	27.8
E5-V (LLaVA-1.6) (Jiang et al., 2024a)	21.8	4.9	11.5	19.0	13.3
MMRet-MLLM (LLaVA-1.6)	<u>47.2</u>	18.4	<u>56.5</u>	62.2	44.0

在零样本和监督微调设置下均取得了最佳性能，涵盖分类、视觉问答、检索和视觉定位四个元任务。

GLM-4-Voice (202412)

GLM-4-Voice 是智谱 AI 推出的端到端语音模型。GLM-4-Voice 能够直接理解和生成中英文语音，进行实时语音对话，并且能够遵循用户的指令要求改变语音的情感、语调、语速、方言等属性。

- ✓ GLM-4-Voice-Tokenizer: 通过在 Whisper 的 Encoder 部分增加 Vector Quantization 并在 ASR 数据上有监督训练，将连续的语音输入转化为离散的 token。每秒音频平均只需要用 12.5 个离散 token 表示。
- ✓ GLM-4-Voice-Decoder: 基于 CosyVoice 的 Flow Matching 模型结构训练的支持流式推理的语音解码器，将离散化的语音 token 转化为连续的语音输出。最少只需要 10 个语音 token 即可开始生成，降低端到端对话延迟。



<https://github.com/THUDM/GLM-4-Voice>


Qwen-VL (202504)

Qwen2.5-VL 是 Qwen 系列模型的最新版本之一，专注于视觉-语言 (Vision-Language) 任务。它在 Qwen2-VL 的基础上进行了升级，进一步提升了多模态任务的性能。

- ✓ 图像理解与描述：解析图像内容，识别物体、场景，生成自然语言描述。支持图像内容的细粒度分析，例如物体属性、位置等。
- ✓ 数学推理与逻辑分析：支持解决复杂的数学问题，包括几何、代数等。支持多步骤推理，逻辑清晰，条理分明。
- ✓ 文本生成与对话：根据输入的文本或图像生成自然语言回答。支持多轮对话，根据上下文进行连贯交流
- ✓ 视觉问答：根据图像内容回答相关问题，例如物体识别、场景描述等。支持复杂的视觉逻辑推导，例如判断物体之间的关系。

<https://github.com/QwenLM/Qwen2.5-VL>

Qwen-VL (202504)



Qwen-VL (202504)

QwenVL HTML Format

```
<html><body>
# paragraph
<p data-bbox="x1 y1 x2 y2"> content </p>
# table
<style>table{id} style</style><table data-bbox="x1 y1 x2 y2" class="table{id}"> table content
</table>
# chart
<div class="chart" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1 x2 y2" /><table> chart content
</table></div>
# formula
<div class="formula" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1 x2 y2" /> <div> formula
content </div></div>
# image caption
<div class="image caption" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1 x2 y2" /><p> image
caption </p></div>
# image ocr
<div class="image ocr" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1 x2 y2" /><p> image ocr
</p></div>
# music sheet
<div class="music sheet" format="abc notation" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1
x2 y2" /> <div> music sheet content </div></div>
# chemical formula content
<div class="chemical formula" format="smile" data-bbox="x1 y1 x2 y2"> <img data-bbox="x1 y1
x2 y2" /> <div> chemical formula content </div></div>
</html></body>
```

Qwen-Omni (202504)

Qwen2.5-Omni 是阿里开源的 Qwen 系列旗舰级多模态模型，拥有7B参数，Qwen2.5-Omni 具备强大的多模态感知能力，能处理文本、图像、音频和视频输入，支持流式文本生成与自然语音合成输出，能实现实时语音和视频聊天。

- ✓ 文本处理：理解、处理各种文本输入，包括自然语言对话、指令、长文本等，支持多种语言。
- ✓ 图像识别：支持识别和理解图像内容。
- ✓ 音频处理：具备语音识别能力，将语音转换为文本，能理解语音指令，生成自然流畅的语音输出。
- ✓ 视频理解：支持处理视频输入，同步分析视频中的视觉和音频信息，实现视频内容理解、视频问答等功能。
- ✓ 实时语音和视频聊天：支持实时处理语音和视频流，实现流畅的语音和视频聊天功能。

Qwen-Omni (202504)

Video-Chat

Query:
What did the person on the left and the person on the right say, respectively?



Response:



(The person on the left says, "Welcome everyone to the show."
The person on the right says,
"I'm very happy that everyone can watch our show.")

Image-Chat

Query:
Please help me solve this math problem.

$$\begin{aligned} X + Y &= 10 \\ X &= 2 \\ Y &= ? \end{aligned}$$




Response:




(Well, since $X + Y = 10$ and $X = 2$, you can just substitute the value of X into the first equation. So it becomes $2 + Y = 10$. Then, if you subtract 2 from both sides, you get $Y = 8$. So, Y equals 8.)

Streaming Codec Decoder



Qwen2.5-Omni Talker



Qwen2.5-Omni Thinker



Vision Encoder

See

Audio Encoder

Hear



Qwen2.5-Omni

Text-Chat

Query:
Mother's Day is coming soon. Can you help me write a message for my mom?



Response:



("Mom, Mother's Day is almost here, and I just wanted to tell you how much you mean to me. You've always been there for me, no matter what. Your love has shaped who I am today. Thank you for everything you've done for me. I hope this Mother's Day brings you so much joy and happiness.")

Audio-Chat

Query:
Please provide a brief description of this music.



Response:




(It's a pop song in A major with a 4/4 time signature. The chord progression mainly alternates between A major and D major. It has a tempo of about 90 BPM)

DeepSeek-OCR


DeepEncoder (视觉编码器)：负责将二维文本图像映射成数量大大减少的视觉 tokens。
窗口注意力 和 **全局注意力编码器** 的串行连接，以高效处理高分辨率输入。
卷积压缩器 在进入全局注意力之前大幅减少视觉 tokens 的数量。

DeepSeek3B-MoE-A570M (解码器)：紧凑的 **专家混合 (MoE)** 架构模型，它接收压缩后的视觉 tokens，并将其解码回原始的文本信息。MoE 设计使其能够高效推理并保持高准确率。



DeepSeek-OCR

Model	Tokens	English					Chinese				
		overall	text	formula	table	order	overall	text	formula	table	order
Pipeline Models											
Dolphin [11]	-	0.356	0.352	0.465	0.258	0.35	0.44	0.44	0.604	0.367	0.351
Marker [1]	-	0.296	0.085	0.374	0.609	0.116	0.497	0.293	0.688	0.678	0.329
Mathpix [2]	-	0.191	0.105	0.306	0.243	0.108	0.364	0.381	0.454	0.32	0.30
MinerU-2.1.1 [34]	-	0.162	0.072	0.313	0.166	0.097	0.244	0.111	0.581	0.15	0.136
MonkeyOCR-1.2B [18]	-	0.154	0.062	0.295	0.164	0.094	0.263	0.179	0.464	0.168	0.243
PPstructure-v3 [9]	-	0.152	0.073	0.295	0.162	0.077	0.223	0.136	0.535	0.111	0.11
End-to-end Models											
Nougat [6]	2352	0.452	0.365	0.488	0.572	0.382	0.973	0.998	0.941	1.00	0.954
SmolDocling [25]	392	0.493	0.262	0.753	0.729	0.227	0.816	0.838	0.997	0.907	0.522
InternVL2-76B [8]	6790	0.44	0.353	0.543	0.547	0.317	0.443	0.29	0.701	0.555	0.228
Qwen2.5-VL-7B [5]	3949	0.316	0.151	0.376	0.598	0.138	0.399	0.243	0.5	0.627	0.226
OLMOCR [28]	3949	0.326	0.097	0.455	0.608	0.145	0.469	0.293	0.655	0.652	0.277
GOT-OCR2.0 [38]	256	0.287	0.189	0.360	0.459	0.141	0.411	0.315	0.528	0.52	0.28
OCRFlux-3B [3]	3949	0.238	0.112	0.447	0.269	0.126	0.349	0.256	0.716	0.162	0.263
GPT4o [26]	-	0.233	0.144	0.425	0.234	0.128	0.399	0.409	0.606	0.329	0.251
InternVL3-78B [42]	6790	0.218	0.117	0.38	0.279	0.095	0.296	0.21	0.533	0.282	0.161
Qwen2.5-VL-72B [5]	3949	0.214	0.092	0.315	0.341	0.106	0.261	0.18	0.434	0.262	0.168
dots.ocr [30]	3949	0.182	0.137	0.320	0.166	0.182	0.261	0.229	0.468	0.160	0.261
Gemini2.5-Pro [4]	-	0.148	0.055	0.356	0.13	0.049	0.212	0.168	0.439	0.119	0.121
MinerU2.0 [34]	6790	0.133	0.045	0.273	0.15	0.066	0.238	0.115	0.506	0.209	0.122
dots.ocr ^{†200dpi} [30]	5545	0.125	0.032	0.329	0.099	0.04	0.16	0.066	0.416	0.092	0.067
DeepSeek-OCR (end2end)											
Tiny	64	0.386	0.373	0.469	0.422	0.283	0.361	0.307	0.635	0.266	0.236
Small	100	0.221	0.142	0.373	0.242	0.125	0.284	0.24	0.53	0.159	0.205
Base	256(182)	0.137	0.054	0.267	0.163	0.064	0.24	0.205	0.474	0.1	0.181
Large	400(285)	0.138	0.054	0.277	0.152	0.067	0.208	0.143	0.461	0.104	0.123
Gundam	795	0.127	0.043	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.103
Gundam-M ^{†200dpi}	1853	0.123	0.049	0.242	0.147	0.056	0.157	0.087	0.377	0.08	0.085



(b) Performance on Omnidocbench